

Proyecto de Aprendizaje Automático

Segmentación de Siniestros Viales mediante K-Means

Alumna: Rojas, Paola

1. Descripción del Proyecto

El proyecto consiste en aplicar técnicas de Aprendizaje Automático No Supervisado para identificar patrones y agrupamientos de siniestros viales ocurridos en las autopistas urbanas durante el año 2024.

A partir de variables relacionadas con la ubicación del accidente, las condiciones meteorológicas, el estado de la vía, el horario y los vehículos involucrados, se buscará detectar grupos de siniestros con características similares.

La finalidad es comprender mejor el comportamiento de los accidentes y descubrir patrones ocultos que permitan identificar zonas, horarios o condiciones asociadas a una mayor concentración de eventos viales.

2. Formulación de Objetivos

Objetivo General

Aplicar técnicas de agrupamiento (clustering) para identificar segmentos o patrones de siniestros viales con características similares, utilizando información geográfica, temporal y contextual del dataset.

Objetivos Específicos

Analizar y comprender la estructura del dataset de siniestros viales.

Preparar y transformar los datos para su utilización en algoritmos de clustering.

Identificar grupos de siniestros similares considerando variables como autopista, punto kilométrico, horario, condiciones meteorológicas y tipo de siniestro.

Aplicar el algoritmo K-Means para segmentar los registros en diferentes clusters.

Comparar distintos valores de k mediante el Método del Codo y el Silhouette Score para determinar la cantidad adecuada de grupos.

Interpretar las características principales de cada cluster encontrado y describir los patrones identificados.

3. Contexto del Problema y Relevancia

Contexto

Los siniestros viales representan uno de los principales problemas de seguridad en las grandes ciudades. La ocurrencia de accidentes está influenciada por múltiples factores, entre ellos las condiciones climáticas, el estado de la vía, el horario, el tipo de vehículo involucrado y la ubicación geográfica donde ocurre el hecho.

Las autopistas urbanas presentan características diferentes según el tramo, el sentido de circulación y el flujo vehicular, lo que genera distintos escenarios de riesgo.

Relevancia

Identificar patrones de siniestralidad permite comprender mejor cómo se comportan los accidentes en diferentes contextos.

Los resultados obtenidos podrían ser utilizados para:

Detectar zonas con comportamientos similares.

Identificar horarios con mayor concentración de accidentes.

Analizar la influencia de las condiciones climáticas.

Mejorar la planificación de medidas preventivas y de seguridad vial.

Optimizar la distribución de recursos de asistencia y emergencia.

4. Definición del Tipo de Problema

El presente proyecto corresponde a un problema de Aprendizaje No Supervisado.

No existe una variable objetivo o etiqueta que indique previamente a qué grupo pertenece cada siniestro.

El propósito del análisis es descubrir patrones ocultos y agrupamientos naturales dentro de los datos mediante técnicas de clustering.

El algoritmo buscará formar grupos de siniestros que compartan características similares, permitiendo identificar distintos perfiles de accidentes sin necesidad de contar con categorías predefinidas.

5. Modelo de Aprendizaje Automático Propuesto

K-Means

El algoritmo K-Means es una técnica de clustering ampliamente utilizada en problemas de segmentación de datos.

Su funcionamiento consiste en agrupar observaciones similares en diferentes clusters a partir de la distancia entre los registros y los centroides de cada grupo.

En este proyecto, K-Means permitirá:

Identificar patrones de siniestros similares.

Descubrir agrupamientos asociados a determinadas autopistas o puntos kilométricos.

Detectar combinaciones frecuentes entre horario, clima y tipo de accidente.

Analizar perfiles de siniestros según los vehículos involucrados.

La cantidad óptima de clusters será determinada mediante:

Método del Codo

Silhouette Score.

Estos métodos permitirán justificar la selección del valor de k más adecuado para representar la estructura de los datos.

Dataset Utilizado

El proyecto utilizará el dataset siniestros-2024.csv, que contiene información sobre accidentes ocurridos en autopistas urbanas durante el año 2024.

Las principales variables analizadas serán:

FECHA

HORA

AUTOPISTA

BANDA y/o RAMAL

PK

CONDICIONES METEOROLÓGICAS

SUPERFICIE DE LA VIA

LESIONADOS

FALLECIDOS

TIPO DE SINIESTRO

MOTO

LIVIANO

BUS

CAMION